

Cervix Visual AI: Desenvolvimento de um Pipeline de Aprendizado Profundo para Classificação de Lesões Cervicais em Imagens de Inspeção Visual com Ácido Acético

[Nome do(a) Autor(a)]¹

¹[Curso / Departamento] – [Instituição de Ensino] (SIGLA)

[Endereço] – [Cidade] – [UF] – Brasil

ueldomiguel@gmail.com

Abstract.

This technical report describes the development of Cervix Visual AI, a single-file Python deep-learning pipeline for binary classification of post-acetic-acid cervical images from the IARC Cervical Image Bank into negative_or_low_grade and high_grade_or_cancer. We report the full development process — proposal, implementation and evaluation — covering automated data preparation, patient-level stratified splitting, aggressive data augmentation, an EfficientNet-B3 backbone fine-tuned in two stages, a class-weighted Focal loss, MixUp regularization, cosine-annealing scheduling, four-view test-time augmentation, temperature-scaling calibration, sensitivity-constrained threshold selection, case-level aggregation, bootstrap confidence intervals and Grad-CAM explainability. The software architecture and its object-oriented design are documented with UML diagrams. Results are framed as an exploratory research artifact without established clinical validity.

Resumo.

Este relatório técnico descreve o desenvolvimento do Cervix Visual AI, um pipeline de aprendizado profundo em arquivo único (Python) para classificação binária de imagens cervicais pós-ácido acético do IARC Cervical Image Bank em negative_or_low_grade e high_grade_or_cancer. Relata-se o processo completo — proposta, desenvolvimento e avaliação — abrangendo preparação automatizada dos dados, divisão estratificada por paciente, aumento agressivo de dados, uma rede EfficientNet-B3 ajustada em duas fases, perda Focal ponderada por classe, regularização por MixUp, escalonamento de taxa por cosseno, aumento em tempo de teste de quatro vistas, calibração por temperatura, seleção de limiar com restrição de sensibilidade, agregação por caso, intervalos de confiança via bootstrap e explicabilidade por Grad-CAM. A arquitetura de software e seu projeto orientado a objetos são documentados com diagramas UML. Os resultados são apresentados como artefato de pesquisa exploratória, sem validade clínica estabelecida.

1. Introdução

O câncer do colo do útero é o quarto tipo de câncer mais comum entre mulheres em todo o mundo, com aproximadamente 570 mil novos casos e cerca de 342 mil óbitos

estimados em 2020, concentrando-se de forma desproporcional em países de baixa e média renda [12]. Em contextos de recursos limitados, a inspeção visual com ácido acético (IVA) continua sendo amplamente utilizada como estratégia de rastreamento de baixo custo, apesar de sua reconhecida dependência do examinador e de sua variabilidade interobservador [1].

Técnicas de visão computacional e aprendizado profundo têm sido propostas como apoio à decisão para padronizar a interpretação de exames de IVA. Um estudo de referência do National Cancer Institute demonstrou que a avaliação visual automatizada baseada em aprendizado profundo identificou casos de pré-câncer/câncer com AUC de 0,91, superando a interpretação humana (AUC 0,69) e a citologia convencional (AUC 0,71) [3]. A International Agency for Research on Cancer (IARC) constituiu o IARC Cervical Image Bank para suprir a carência de bancos de imagens padronizados para o desenvolvimento de tais algoritmos [2].

Este relatório técnico descreve o desenvolvimento do Cervix Visual AI, um pipeline de visão computacional implementado em um único arquivo Python para a classificação binária de imagens “After acetic acid” em `negative_or_low_grade` e `high_grade_or_cancer`. O texto está organizado de modo a percorrer as três etapas do trabalho: a proposta (Seção 3), com objetivos, requisitos e metodologia de desenvolvimento; o desenvolvimento (Seção 4), com a arquitetura de software e a descrição técnica de cada componente; e a avaliação (Seção 5), com o protocolo de métricas, os artefatos produzidos e a evolução do pipeline. A Seção 2 apresenta trabalhos relacionados, a Seção 6 discute ética, limitações e trabalhos futuros, e a Seção 7 conclui. Cabe ressaltar que, conforme declarado na própria documentação do código, trata-se de um artefato experimental cujos resultados não devem ser utilizados para decisão clínica.

2. Trabalhos Relacionados

O estudo de Hu et al. [3] estabeleceu empiricamente que modelos de aprendizado profundo podem superar a avaliação visual humana não assistida na triagem cervical, reportando AUC de 0,91 (IC 95% 0,89–0,93). Especificamente sobre o IARC Cervical Image Bank, um trabalho recente combinou características de variantes ResNet, reduzidas por LDA e classificadas por SVM, reportando especificidade, sensibilidade e acurácia de 97% a 99% na tarefa normal/anormal [5]. Em abordagem multimodal, o sistema DeepCerviCancer combina modelos de colposcopia e citologia, atingindo valores elevados de F1 e precisão quando ambas as modalidades estão disponíveis [4]. Para cenários de baixos recursos, um pipeline leve com EfficientDet-Lite e MobileNet, executado em dispositivo Android, reportou acurácia de 92,31%, sensibilidade de 98,24% e especificidade de 88,37% [6].

O Cervix Visual AI diferencia-se pela combinação de rigor metodológico no tratamento dos dados (divisão por paciente com verificação de vazamento e agregação por caso) com um conjunto moderno de técnicas de regularização, calibração e interpretabilidade — perda Focal, MixUp, escalonamento por cosseno, TTA de quatro vistas, calibração por temperatura, limiar com restrição de sensibilidade, intervalos de confiança via bootstrap e mapas Grad-CAM — frequentemente subespecificados em pipelines comparáveis.

3. Proposta

3.1 Objetivos

O objetivo geral do trabalho foi desenvolver um pipeline reproduzível, de ponta a ponta, para a classificação binária de imagens de IVA do IARC Cervical Image Bank, com ênfase em robustez estatística e interpretabilidade. Como objetivos específicos, definiram-se: (i) automatizar a preparação dos dados a partir do arquivo distribuído pela IARC; (ii) evitar vazamento de dados por meio de divisão e avaliação no nível do paciente; (iii) treinar uma rede convolucional moderna por transferência de aprendizado; (iv) calibrar tanto as probabilidades quanto o limiar de decisão segundo prioridades clínicas; (v) quantificar a incerteza das métricas; e (vi) gerar explicações visuais das predições.

3.2 Requisitos e decisões de projeto

A partir dos objetivos, estabeleceram-se requisitos que orientaram as decisões de projeto, resumidos na Tabela 1.

Tabela 1. Requisitos do projeto e respectivas decisões de projeto.

Requisito	Decisão de projeto
Reprodutibilidade e simplicidade de distribuição	Implementação em arquivo único Python, com semente fixa e CLI por subcomandos.
Ausência de vazamento de dados	Divisão estratificada por patient_id e agregação de predições por caso.
Desempenho com poucos dados	Transferência de aprendizado, aumento agressivo de dados, MixUp e SWA-like scheduling.
Sensibilidade clínica (evitar falsos negativos)	Perda Focal com pos_weight e limiar que maximiza F1 sob Sens $\geq 0,80$.
Confiabilidade das probabilidades	Calibração por escalonamento de temperatura (temperature scaling).
Quantificação de incerteza	Intervalos de confiança de 95% via bootstrap por caso.
Interpretabilidade	Mapas Grad-CAM por classe e por quadrante da matriz de confusão.

3.3 Metodologia de desenvolvimento

O desenvolvimento seguiu um processo iterativo e incremental. Uma primeira versão, baseada em ResNet-34 e com função de perda BCE com suavização de rótulos, serviu de prova de conceito e expôs limitações de implementação (descritas na Seção 5.3). A versão atual, documentada neste relatório, evoluiu para um backbone EfficientNet-B3, incorporou perda Focal, MixUp, escalonamento por cosseno com reinícios, TTA de quatro vistas, calibração por temperatura, limiar com restrição de sensibilidade e explicabilidade por Grad-CAM, além de corrigir defeitos identificados na iteração anterior. Cada incremento foi validado pelo protocolo de avaliação da Seção 5, comparando-se métricas por caso entre versões.

4. Desenvolvimento

4.1 Arquitetura de software e visão de processo

O Cervix Visual AI é estruturado como uma arquitetura em camadas, com responsabilidades bem delimitadas e fluxo de controle descendente. A Figura 1 apresenta a visão de processo — a sequência de transformações aplicadas aos dados, da leitura do arquivo da IARC até a geração de métricas e mapas de explicabilidade.




Figura 1. Visão de processo do pipeline Cervix Visual AI, da ingestão dos dados à avaliação por caso, calibração e interpretabilidade.

A Figura 2 apresenta a visão estrutural complementar: a organização do software em camadas (Interface, Orquestração, Dados, Modelo, Treino e Otimização, Inferência e Calibração, Avaliação e Métricas, Explicabilidade e Saída) e sua dependência das bibliotecas externas. Cada camada depende apenas de serviços expostos pelas camadas inferiores, o que reduz o acoplamento e facilita a substituição de componentes.

Arquitetura de software em camadas do Cervix Visual AI




Figura 2. Arquitetura de software em camadas; à direita, as bibliotecas externas utilizadas (PyTorch/torchvision, scikit-learn, pandas/NumPy, matplotlib/Plotly, OpenCV/PIL).

4.2 Dados: preparação e divisão por paciente

O pipeline pressupõe o acesso a um arquivo ZIP do IARC Cervical Image Bank, contendo as planilhas “Cases - Images.xlsx” e “Cases Meta data.xlsx” e os arquivos de imagem [2]. A função `prepare_iarc_dataset()` restringe-se às imagens do tipo “After acetic acid”, extrai cada imagem e gera dois manifestos (`manifest.csv`, por imagem; `case_manifest.csv`, por caso). O rótulo binário não é fornecido diretamente: é derivado por mineração de texto do campo “Provisional diagnosis” — `normalize_text()` limpa o texto e `derive_target()` atribui `high_grade_or_cancer` caso haja termos como “hsil”, “cin2/3”, “carcinoma” ou “cancer”, e `negative_or_low_grade` caso contrário. Trata-se de rotulagem fraca (weak labeling), cuja limitação (ausência de tratamento de negação) é discutida na Seção 6.

A divisão dos dados é estratificada e realizada no nível do paciente (Figura 3): 70% dos casos para treino e os 30% restantes divididos igualmente entre validação e teste (≈70/15/15). Como um caso pode contribuir com múltiplas imagens, dividir por imagem

configuraria vazamento de dados; `load_manifest()` verifica que cada paciente pertence a uma única divisão, e a avaliação é sempre agregada por caso.




Figura 3. Divisão estratificada no nível do paciente, evitando vazamento de dados entre as divisões.

4.3 Modelo, aumento de dados e treinamento

A classe `CervixImageDataset` carrega cada imagem, aplica as transformações e valida o tensor (NaN/Inf). O pipeline de treino adota um esquema de aumento de dados agressivo (Tabela 2), voltado a mitigar o sobreajuste em um conjunto médico pequeno; o pipeline de avaliação é determinístico (redimensionamento, tensor e normalização ImageNet).

Tabela 2. Operações de aumento de dados aplicadas ao conjunto de treino.

Operação de aumento (treino)	Parâmetros
Resize + RandomCrop	sobredimensiona +15% e recorta para <code>image_size</code>
RandomHorizontalFlip / VerticalFlip	$p = 0,50$ / $p = 0,30$
RandomRotation	$\pm 30^\circ$
RandomPerspective	<code>distortion_scale</code> = 0,35; $p = 0,50$
RandomAffine	rot 20°, translação 12%, escala 0,80–1,20, shear 12
ColorJitter	brilho 0,45; contraste 0,40; saturação 0,35; matiz 0,12
Sharpness / Autocontrast / GaussianBlur / Grayscale	$p = 0,40$ / 0,30 / sempre / 0,05
RandomErasing ($\times 2$)	$p = 0,35$ e $p = 0,25$ (escalas distintas)

A função `build_model()` instancia, por padrão, uma EfficientNet-B3 pré-treinada na ImageNet [13], escolhida pelo bom equilíbrio entre acurácia e custo proporcionado pelo escalonamento composto. A Tabela 3 lista as quatro arquiteturas efetivamente suportadas.

Tabela 3. Arquiteturas de backbone suportadas por `build_model()`.

Arquitetura	Observações
<code>efficientnet_b3</code>	Padrão; escalonamento composto; equilíbrio acurácia/custo [13]
<code>efficientnet_b4</code>	Maior capacidade e campo receptivo [13]
<code>resnet34</code>	Linha de base com conexões residuais [9]
<code>convnext_tiny</code>	ConvNet moderna; boa calibração [14]

Independentemente do backbone, a camada de classificação é substituída por uma cabeça de duas camadas (Figura 4): Dropout(0,40) → Linear(256) → ReLU → Dropout(0,20) → Linear(1). A transferência de aprendizado ocorre em duas fases (Figura 5): nas primeiras cinco épocas o backbone é congelado e apenas a cabeça é treinada; em seguida, a rede inteira é ajustada, com taxa de aprendizado do backbone igual a $0,1 \times$ a da cabeça.



Figura 4. Cabeça de classificação de duas camadas sobre o vetor de características do backbone.




Figura 5. Transferência de aprendizado em duas fases (congelamento inicial seguido de ajuste fino completo).

O desbalanceamento é tratado pelo `pos_weight` da perda, calculado por caso e multiplicado por um fator (1,5). Duas perdas estão disponíveis (Tabela 4): a Focal Loss ($\gamma = 2,0$), padrão, que concentra o aprendizado nos exemplos difíceis [15]; e a BCE com suavização de rótulos. O otimizador é o AdamW [10] com taxas diferenciadas, e o agendamento usa CosineAnnealingWarmRestarts ($T_0 = 10$, $T_{mult} = 2$). O laço de treino aplica MixUp [18] e recorte de norma de gradiente, e calcula métricas de treino e validação por época. A Tabela 5 resume os hiperparâmetros padrão.

Tabela 4. Funções de perda disponíveis (ambas com `pos_weight`).

Função de perda	Descrição
FocalLoss (padrão)	BCE modulada por $(1 - p_t)^\gamma$, $\gamma = 2,0$; foca exemplos difíceis [15]
LabelSmoothingBCE	BCE com suavização de rótulos de 0,05; melhora a calibração

Tabela 5. Hiperparâmetros padrão de treinamento.

Hiperparâmetro	Valor padrão
architecture / pretrained	efficientnet_b3 / True (ImageNet)
image_size / batch_size	$384 \times 384 / 16$ (8 na CLI)
epochs / freeze_backbone_epochs / patience	30 / 5 / 20

learning_rate (cabeça) / backbone	3×10^{-4} / $0,1 \times$
weight_decay	1×10^{-2}
loss_type / pos_weight_multiplier	focal ($\gamma = 2,0$) / 1,5
mixup_alpha / dropout	0,4 / 0,40 e 0,20
scheduler	CosineAnnealingWarmRestarts (T_0=10, T_mult=2)
temperature_scaling / bootstrap / seed	True / 500 / 42

4.4 Inferência: TTA, calibração e limiar

Na inferência, `predict_loader()` aplica aumento em tempo de teste com quatro vistas geométricas (original, espelhamentos horizontal, vertical e duplo), cujas probabilidades são calculadas em média (Figura 6). As predições por imagem são agregadas por paciente (média), e `optimize_threshold()` seleciona o limiar que maximiza o F1 entre aqueles que garantem sensibilidade $\geq 0,80$ — refletindo a prioridade clínica de minimizar falsos negativos. Após o treino, `_calibrate_temperature()` ajusta um escalar T por L-BFGS [16], suavizando probabilidades super-confiantes sem alterar o ranqueamento; T é armazenado no checkpoint e aplicado em toda inferência.




Figura 6. Inferência: agregação de quatro vistas de TTA, calibração por temperatura e decisão por limiar com restrição de sensibilidade.

4.5 Interpretabilidade: Grad-CAM

A explicabilidade visual é fornecida por Grad-CAM [17]: a classe GradCAM registra ganchos sobre a última camada convolucional do backbone e combina ativações ponderadas pelos gradientes da classe-alvo para produzir mapas de calor. A função `generate_gradcam_exemplars()` seleciona exemplares de cada quadrante da matriz de confusão (TP/TN/FP/FN), úteis para auditoria de erros, e `generate_gradcam_dataset()` estende a geração a todo o conjunto.

4.6 Organização orientada a objetos e modelagem UML

Quatro classes concentram as responsabilidades de domínio (Tabela 6). A Figura 7 apresenta o diagrama de classes UML, e a Figura 8, o diagrama de dependências.

Tabela 6. Classes do Cervix Visual AI, superclasses e responsabilidades.

Classe	Superclasse	Responsabilidade
CervixImageDataset	torch.utils.data.Dataset	Carrega imagens, aplica transformações e valida o tensor

		(NaN/Inf).
FocalLoss	torch.nn.Module	Perda Focal com pos_weight; foca exemplos difíceis.
LabelSmoothingBCE	torch.nn.Module	BCE com suavização de rótulos e pos_weight.
GradCAM	— (autônoma)	Registra ganchos e gera o mapa de ativação de classe.

O diagrama de classes (Figura 7) evidencia três generalizações: FocalLoss e LabelSmoothingBCE especializam torch.nn.Module, sobrescrevendo forward(); e CervixImageDataset especializa torch.utils.data.Dataset, implementando __len__() e __getitem__(). A classe GradCAM não herda de nenhuma superclasse, mas mantém uma associação com um objeto Module (o modelo a ser explicado) — composição em vez de herança. Manifestam-se assim os três pilares da orientação a objetos: encapsulamento (o atributo privado _handles e os métodos _register_hooks()/remove_hooks() de GradCAM); herança (perdas e dataset reutilizando a infraestrutura do PyTorch); e polimorfismo (a variável criterion referenciando FocalLoss ou LabelSmoothingBCE, ambas chamadas via forward()).

Diagrama de classes UML do Cervix Visual AI




Figura 7. Diagrama de classes UML: classes de domínio, superclasses do PyTorch e a associação entre GradCAM e o modelo.

A Figura 8 mostra como a função orquestradora train_model() depende de build_model() (que instancia o modelo), de uma das funções de perda e de create_data loaders() (que encapsula objetos CervixImageDataset). Essa separação

favorece a manutenibilidade: novas perdas, backbones ou técnicas de interpretabilidade podem ser adicionados sem alterar o laço de treinamento.




Figura 8. Diagrama UML de dependências: `train_model()` orquestra fábricas, critério de perda, conjunto de dados e explicabilidade.

4.7 Interface de linha de comando

O script expõe seis subcomandos (Tabela 7); sem argumentos, assume train.

Tabela 7. Subcomandos da interface de linha de comando.

Comando	Função
prepare	Extraí o ZIP da IARC e gera os manifestos.
demo	prepare seguido de treino com hiperparâmetros fixos.
train	Treino configurável (arquitetura, perda, limiar, temperatura etc.).
evaluate	Reexecuta a avaliação (com TTA e temperatura) sobre um checkpoint.
predict	Inferência em imagem única, com probabilidade calibrada e rótulo.
show	Exibe imagens ou mapas Grad-CAM no terminal.

5. Avaliação

5.1 Protocolo e métricas

A avaliação é reportada no nível do caso. A função `binary_metrics()` calcula acurácia, acurácia balanceada, sensibilidade, especificidade, precisão (PPV), valor preditivo negativo, F1 e escore de Brier; quando ambas as classes estão presentes, calcula

também AUC-ROC e precisão média. A seleção do melhor modelo a cada época usa um escore composto ($0,5 \times \text{AUC-ROC} + 0,3 \times \text{F1} + 0,2 \times \text{acurácia balanceada}$), equilibrando discriminação e desempenho operacional. A função `bootstrap_confidence_intervals()` realiza 500 reamostragens com reposição por caso, reportando os percentis 2,5 e 97,5 de cada métrica como intervalo de confiança aproximado de 95% — adequado às amostras reduzidas de estudos de centro único.

5.2 Artefatos produzidos

Uma execução completa do subcomando `train` produz o conjunto de artefatos da Tabela 8, incluindo o checkpoint autossuficiente (com limiar e temperatura), os relatórios em JSON, as predições por caso em CSV, os gráficos e os painéis Grad-CAM.

Tabela 8. Artefatos produzidos por uma execução completa de `train`.

Artefato	Conteúdo
<code>best_model.pt</code>	Pesos, arquitetura, dropout, <code>image_size</code> , limiar e temperatura.
<code>training_history.json</code>	Métricas de treino/validação e limiar por época.
<code>training_summary.json</code>	Resumo: dispositivo, tempo, peso positivo, melhor época.
<code>evaluation_metrics.json</code>	Métricas por divisão (imagem e caso) com IC bootstrap.
<code>{split}_case_predictions.csv</code>	Probabilidade e predição por caso, por divisão.
Gráficos (PNG/HTML)	Perda, ROC, precisão-revocação, matriz de confusão, painel.
Painéis Grad-CAM	Exemplares TP/TN/FP/FN e mapas do conjunto completo.

5.3 Evolução do pipeline

A Tabela 9 sintetiza a evolução entre a versão inicial (ResNet-34) e a versão atual (EfficientNet-B3), evidenciando tanto correções de defeitos quanto a incorporação de novas técnicas — o resultado direto da metodologia iterativa descrita na Seção 3.3.

Tabela 9. Evolução do pipeline entre as iterações de desenvolvimento.

Aspecto	Versão inicial (ResNet-34)	Versão atual (EfficientNet-B3)
Backbone	Apenas ResNet-34 (EfficientNet não construído)	EfficientNet-B3/B4, ResNet-34, ConvNeXt-Tiny
Cabeça	Dropout → Linear(1)	Dropout → Linear(256) → ReLU → Dropout → Linear(1)
Perda	BCE com suavização	Focal Loss (padrão) + BCE com suavização
Scheduler	ReduceLROnPlateau	CosineAnnealingWarmRestarts
TTA	2 vistas	4 vistas (orig, H, V, HV)
Calibração	Ausente	Escalonamento de temperatura (L-BFGS)
Limiar	Maximiza F1	Maximiza F1 com $\text{Sens} \geq 0,80$
Early stopping	Inoperante (bug)	Corrigido e funcional
Interpretabilidade	Ausente	Grad-CAM (exemplares e conjunto)
Inferência única	Retornava logit bruto	Probabilidade calibrada + rótulo

5.4 Resultados esperados e contextualização

Este relatório documenta o projeto e a implementação, e não relata o resultado de uma execução específica, uma vez que a execução completa depende do acesso ao arquivo licenciado da IARC, não reproduzido neste trabalho [2]. A título de contextualização — e não de previsão de desempenho —, trabalhos correlatos sobre o banco da IARC relataram métricas entre 97% e 99% [5] e, em soluções móveis, acurácia $\approx 92\%$ [6]. Tais valores referem-se a conjuntos e definições de rótulo distintos e não devem ser interpretados como estimativa do desempenho deste pipeline. Recomenda-se que qualquer relato priorize as métricas no nível do caso, com intervalos de confiança de 95%, o limiar calibrado, a temperatura e a distribuição de classes por divisão.

6. Discussão: Ética, Limitações e Trabalhos Futuros

O próprio código declara que os resultados são experimentais e não devem ser usados para decisão clínica — afirmação que este relatório reitera. O acesso às imagens da IARC está sujeito aos procedimentos da instituição, e o uso de imagens médicas pressupõe aprovação ética. Há risco de viés algorítmico e de generalização limitada, dada a diversidade de centros e dispositivos; qualquer aplicação prática exigiria validação clínica prospectiva [8]. Ferramentas dessa natureza enquadram-se melhor como apoio à decisão do que como diagnóstico autônomo, e os mapas Grad-CAM contribuem para a transparência.

Permanecem limitações que deveriam ser tratadas antes de qualquer relato empírico:

- **Rotulagem sem tratamento de negação:** a rotulagem por mineração de texto não trata negação, podendo classificar incorretamente textos que descrevam a ausência da condição; cotejar com o campo Histopathology seria uma alternativa.
- **Caminho padrão específico:** o caminho padrão do ZIP da IARC é específico do ambiente de desenvolvimento, reduzindo a portabilidade.
- **Paralelismo de GPU limitado:** o paralelismo de múltiplas GPUs está desativado nesta versão.
- **Validação externa não automatizada:** a divisão `external_test` não é populada automaticamente, embora suportada.

Como trabalhos futuros, delineiam-se: curadoria de rótulos com revisão por especialistas; validação externa em coorte independente; pré-treinamento de domínio e ensembles por validação cruzada; fusão multimodal incorporando HPV, score de Swede e zona de transformação [4]; e, seguindo [8], validação clínica prospectiva.

7. Conclusão

Este relatório técnico descreveu o desenvolvimento completo do Cervix Visual AI, percorrendo a proposta (objetivos, requisitos e metodologia iterativa), o desenvolvimento (arquitetura de software, dados, modelo EfficientNet-B3, treinamento, inferência calibrada, interpretabilidade e projeto orientado a objetos documentado em UML) e a avaliação (protocolo por caso, artefatos, evolução entre versões e contextualização de resultados). O pipeline combina disciplina no tratamento de dados — divisão e agregação por paciente com quantificação de incerteza — com técnicas modernas de regularização, calibração e explicabilidade, corrigindo defeitos da iteração inicial. Enquadrado honestamente como artefato de pesquisa experimental, oferece um

modelo reproduzível e interpretável, além de um ponto de partida concreto para refinamentos — curadoria de rótulos, validação externa, pré-treinamento de domínio, fusão multimodal e avaliação clínica prospectiva — necessários para que um protótipo evolua, com segurança para as pacientes, em direção a uma ferramenta de apoio ao rastreamento do câncer do colo do útero [1].

Referências

- [1] WORLD HEALTH ORGANIZATION. Global strategy to accelerate the elimination of cervical cancer as a public health problem. Geneva: WHO, 2020.
- [2] INTERNATIONAL AGENCY FOR RESEARCH ON CANCER (IARC). IARC Cervical Cancer Image Bank. Disponível em: <https://screening.iarc.fr/cervicalimagebank.php>. Acesso em: jun. 2026.
- [3] HU, L. et al. An Observational Study of Deep Learning and Automated Evaluation of Cervical Images for Cancer Screening. Journal of the National Cancer Institute, 2019.
- [4] KALBHOR, M. et al. DeepCerviCancer — Deep Learning-Based Cervical Image Classification using Colposcopy and Cytology Images. EAI Endorsed Trans. on Pervasive Health and Technology, 2023.
- [5] Deep Learning Descriptor Hybridization with Feature Reduction for Accurate Cervical Cancer Colposcopy Image Classification. arXiv:2405.01600, 2024.
- [6] Automated Cervical Cancer Detection through Visual Inspection with Acetic Acid in Resource-Poor Settings with Lightweight Deep Learning Models Deployed on an Android Device. arXiv:2508.13253, 2025.
- [7] XUE, Z. et al. Image Quality Classification for Automated Visual Evaluation of Cervical Precancer. In: MILLanD 2022, LNCS v. 13559. Cham: Springer, 2022.
- [8] Development and Clinical Validation of a VIA-Artificial Intelligence Tool in Screen-and-Treat Visual Screening for Cervical Cancer in South India: A Pilot Study. JCO Global Oncology, 2024.
- [9] HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: CVPR, 2016.
- [10] LOSHCHILOV, I.; HUTTER, F. Decoupled Weight Decay Regularization. In: ICLR, 2019.
- [11] DENG, J. et al. ImageNet: A Large-Scale Hierarchical Image Database. In: CVPR, 2009.
- [12] WORLD HEALTH ORGANIZATION. New recommendations for screening and treatment to prevent cervical cancer. Geneva: WHO, 2021.
- [13] TAN, M.; LE, Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In: ICML, 2019.
- [14] LIU, Z. et al. A ConvNet for the 2020s. In: CVPR, 2022.
- [15] LIN, T.-Y. et al. Focal Loss for Dense Object Detection. In: ICCV, 2017.
- [16] GUO, C. et al. On Calibration of Modern Neural Networks. In: ICML, 2017.
- [17] SELVARAJU, R. R. et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In: ICCV, 2017.
- [18] ZHANG, H. et al. mixup: Beyond Empirical Risk Minimization. In: ICLR, 2018.