

Cervix Visual AI: Desenvolvimento de um Pipeline de Deep Learning para Classificação de Lesões Cervicais em Imagens de Inspeção Visual com Ácido Acético

Ueldo Miguel Plentz Rodrigues¹

¹Universidade do Vale do Rio dos Sinos (UNISINOS)
São Leopoldo – RS – Brasil
miguelplentz@edu.unisinos.br

Resumo

Este relatório técnico descreve o desenvolvimento do Cervix Visual AI, um pipeline de aprendizado profundo em arquivo único na linguagem Python para o treinamento, o processamento e a classificação binária de imagens cervicais pós-ácido acético do IARC Cervical Image Bank em `negative_or_low_grade` e em `high_grade_or_cancer`. Relata-se o processo completo - proposta, desenvolvimento e avaliação - abrangendo a preparação automatizada dos dados, a divisão estratificada por paciente, o aumento de dados, uma rede EfficientNet-B3 ajustada em duas fases, a perda focal ponderada por classe, a regularização por MixUp, o escalonamento de taxa por cosseno, o aumento em tempo de teste de quatro vistas, a calibração por temperatura, a seleção de limiar com restrição de sensibilidade, a agregação por caso, intervalos de confiança via bootstrap e explicabilidade por Grad-CAM. A solução extrai características relevantes do colo uterino para auxiliar a interpretação dos achados visuais com a utilização de ácido acético, auxiliar nas condutas a serem adotadas, além de gerar métricas de desempenho como acurácia, sensibilidade, especificidade, F1 score e AUC. A arquitetura de software e seu projeto representando imagens de colo uterino orientado a objetos são documentados com diagramas UML. Os resultados são apresentados como um artefato de pesquisa exploratória, sem validade clínica estabelecida. No pipeline da proposta, está a extração dos dados do dataset IARC Cervical Image Bank, contemplando as imagens digitalizadas do colo uterino, a anotação de alterações morfológicas e a criação de classes, implementando-os na linguagem Python, mediante a utilização de diversas bibliotecas. A revisão bibliográfica mostra que modelos baseados em arquiteturas CNN, ensembles e arquiteturas híbridas CNN-Transformer alcançam resultados elevados em benchmarks públicos, mas ainda apresentam lacunas em validação externa, calibração, generalização geográfica e integração clínica.

Abstract

This technical report describes the development of Cervix Visual AI, a single-file Python deep-learning pipeline for training, processing and binary

classification of post-acetic-acid cervical images from the IARC Cervical Image Bank into negative_or_low_grade and high_grade_or_cancer. We report the full development process - proposal, implementation and evaluation - covering automated data preparation, patient-level stratified splitting, aggressive data augmentation, an EfficientNet-B3 backbone fine-tuned in two stages, a class-weighted Focal loss, MixUp regularization, cosine-annealing scheduling, four-view test-time augmentation, temperature-scaling calibration, sensitivity-constrained threshold selection, case-level aggregation, bootstrap confidence intervals and Grad-CAM explainability. The solution extracts relevant cervical characteristics to help in visual findings interpretation with the utilization of acetic acid, and to help on appropriate management to be adopted, in addition to generating performance metrics such as accuracy, sensitivity, specificity, F1 score and AUC. The software architecture and its object-oriented design are documented with UML diagrams. Results are framed as an exploratory research artifact without established clinical validity. The proposed pipeline involves extracting data from the IARC Cervical Image Bank dataset, including cervix digitized images, annotated morphologic alterations, creation of classes, and implementation in Python using several libraries. A literature review shows that CNN-based architectures, ensembles, and hybrid CNN-Transformer architectures achieve high results in public benchmarks, but still have gaps in external validation, calibration, geographic generalization, and clinical integration.

1. Introdução

O câncer do colo do útero é o quarto tipo de câncer mais comum entre mulheres em todo o mundo, com aproximadamente 570 mil novos casos e cerca de 342 mil óbitos estimados em 2020, concentrando-se de forma desproporcional em países de baixa e média renda [12]. Em contextos de recursos limitados, a inspeção visual com ácido acético (IVA) continua sendo amplamente utilizada como estratégia de rastreamento de baixo custo, apesar de sua reconhecida dependência do examinador e de sua variabilidade interobservador [1].

Técnicas de visão computacional e aprendizado profundo têm sido propostas como apoio à decisão para padronizar a interpretação de exames de IVA. Um estudo de referência do National Cancer Institute demonstrou que a avaliação visual automatizada baseada em aprendizado profundo identificou casos de pré-câncer/câncer com AUC de 0,91, superando a interpretação humana (AUC 0,69) e a citologia convencional (AUC 0,71) [3]. A International Agency for Research on Cancer (IARC) constituiu o IARC Cervical Image Bank para suprir a carência de bancos de imagens padronizados para o desenvolvimento de tais algoritmos [2].

Este relatório técnico descreve o desenvolvimento do Cervix Visual AI, um pipeline de visão computacional implementado em um único arquivo Python para a classificação binária de imagens obtidas após a utilização do ácido

acético em negativo_ou_baixo_grau ou em alto_grau_ou_cancer. O texto está organizado de modo a percorrer as etapas do trabalho. A seção 2 apresenta trabalhos relacionados, a seção 3 apresenta a proposta, com objetivos, requisitos e metodologia de desenvolvimento; a seção 4 traz o desenvolvimento, com a arquitetura de software e a descrição técnica de cada componente; a seção 5 apresenta a avaliação, com o protocolo de métricas, os artefatos produzidos e a evolução do pipeline. a seção 6 discute a ética, as limitações e a sugestão de trabalhos futuros, e a seção 7 traz as conclusões do trabalho. Cabe ressaltar que, conforme declarado na própria documentação do código, trata-se de um artefato experimental cujos resultados não devem ser utilizados para decisão clínica.

2. Trabalhos Relacionados

O estudo de Hu et al. [3] estabelece empiricamente que modelos de aprendizado profundo podem superar a avaliação visual humana não assistida na triagem cervical, reportando AUC de 0,91 (IC 95% 0,89–0,93). Especificamente sobre o IARC Cervical Image Bank, um trabalho recente combinou características de variantes ResNet, reduzidas por LDA e classificadas por SVM, reportando especificidade, sensibilidade e acurácia de 97% a 99% na tarefa normal/anormal [5]. Em abordagem multimodal, o sistema DeepCerviCancer combina modelos de colposcopia e citologia, atingindo valores elevados de F1 score e precisão quando ambas as modalidades estão disponíveis [4]. Para cenários de baixos recursos, um pipeline leve com EfficientDet-Lite e MobileNet, executado em dispositivo Android, reportou acurácia de 92,31%, sensibilidade de 98,24% e especificidade de 88,37% [6].

O Cervix Visual AI diferencia-se pela combinação de rigor metodológico no tratamento dos dados (divisão por paciente com verificação de vazamento e agregação por caso) com um conjunto moderno de técnicas de regularização, calibração e interpretabilidade - perda Focal, MixUp, escalonamento por cosseno, TTA de quatro vistas, calibração por temperatura, limiar com restrição de sensibilidade, intervalos de confiança via bootstrap, com a localização da lesão por bounding box e mapas Grad-CAM.

3. Proposta

3.1 Objetivos

O objetivo geral do trabalho foi desenvolver um *pipeline* reprodutível, de ponta a ponta, para a classificação binária de imagens de IVA do IARC Cervical Image Bank, com ênfase em robustez estatística e interpretabilidade. Como objetivos específicos, definiram-se: (I) automatizar a preparação dos dados a partir do arquivo distribuído pela IARC; (II) evitar vazamento de dados por meio de divisão e avaliação no nível do paciente; (III) treinar uma rede convolucional moderna por transferência de aprendizado; (IV) calibrar tanto as probabilidades quanto o limiar de decisão segundo prioridades clínicas; (V) quantificar a incerteza das métricas; e (VI) gerar explicações visuais das predições.

3.2 Requisitos e decisões de projeto

A partir dos objetivos, estabeleceram-se requisitos que orientaram as decisões de projeto, resumidos na Tabela 1.

Tabela 1. Requisitos estabelecidos para o projeto e soluções

Requisitos para o projeto	Soluções
Reprodutibilidade e simplicidade de distribuição	Implementação em arquivo único Python, com <i>seed</i> fixa e CLI (Command Line Interface) por subcomandos.
Ausência de vazamento de dados	Divisão estratificada por <i>patient_id</i> e agregação de predições por caso.
Desempenho com poucos dados	<i>Transfer learning</i> , <i>data augmentation</i> agressivo, MixUp e SWA-like <i>scheduling</i> .
Sensibilidade clínica (evitar falsos negativos)	Perda Focal com <i>pos_weight</i> e limiar que maximiza F1 score sob Sensibilidade $\geq 0,80$.
Confiabilidade das probabilidades	Calibração por escalonamento de temperatura (<i>temperature scaling</i>).
Quantificação de incerteza	Intervalos de confiança de 95% via <i>bootstrap</i> por caso.
Interpretabilidade	Mapas Grad-CAM e <i>boundingbox</i> por classe e por quadrante da matriz de confusão.

Fonte: Autoria própria

3.3 Metodologia de desenvolvimento

O desenvolvimento seguiu um processo iterativo e incremental. Uma primeira versão, baseada em ResNet-34 e com função de perda BCE com suavização de rótulos serviu de prova de conceito e expôs limitações de implementação (descritas na Seção 5.3). A versão atual, documentada neste relatório, evoluiu para um backbone EfficientNet-B3, incorporou *focal loss*, MixUp, escalonamento por cosseno com reinícios, TTA de quatro vistas, calibração por temperatura, limiar com restrição de sensibilidade e explicabilidade por Grad-CAM e por *boundingbox*. Cada incremento foi validado pelo protocolo de avaliação da Seção 5, comparando-se métricas por caso entre versões.

4. Desenvolvimento

4.1 Arquitetura de software e visão de processo

O Cervix Visual AI é estruturado como uma arquitetura em camadas, com responsabilidades bem delimitadas e fluxo de controle descendente. A Figura 1 apresenta a visão de processo - a sequência de transformações aplicadas aos dados, da leitura do arquivo da IARC até a geração de métricas e mapas de explicabilidade.

```

graph TD
    subgraph Coluna1 [Dados]
        A[ZIP IARC  
(Cases - Images / Meta data)]
        C[CervixImageDataset  
PIL→tensor, checagem NaN]
        E[EfficientNet-B3  
(backbone ImageNet)]
        G[Seleção do modelo  
0,5·AUC+0,3·F1+0,2·BalAcc]
        I[TTA 4 vistas  
(orig, H, V, HV)]
        K[Grad-CAM  
TP / TN / FP / FN]
    end
    subgraph Coluna2 [Pré-proc.]
        B[prepare_iarc_dataset()  
mineração de texto → rótulo]
        D[DataLoaders + Aug.  
forte (treino)]
        F[Cabeça 2 camadas  
Drop→FC256→ReLU→Drop→FC1]
        H[AdamW + Cosine  
WarmRestarts]
        J[Temperature scaling  
(LBFGS, T)]
        L[Agregação por paciente  
(média de probabilidades)]
    end
    subgraph Coluna3 [Modelo]
        IARC[manifest.csv  
case_manifest.csv]
        J1[Divisão por PACIENTE  
70 / 15 / 15 estratificada]
        L1[Fine-tuning 2 fases  
congela 5 épocas]
        M1[Focal Loss + pos_weight  
MixUp + clip de gradiente]
        N1[Limiar clínico  
F1 s.a. Sens ≥ 0,80]
        O1[Métricas por CASO  
+ IC 95% bootstrap]
    end
    A --> B
    B --> IARC
    IARC --> J1
    J1 --> D
    D --> C
    C --> E
    E --> F
    F --> L1
    L1 --> M1
    M1 --> H
    H --> G
    G --> I
    I --> J
    J --> N1
    N1 --> O1
    O1 --> L
    L --> K
    K --> Artefatos
    O1 --> Artefatos
  
```


Artefatos: best_model.pt · *.json · CSV por divisão · gráficos PNG/HTML · painéis Grad-CAM

Legenda:

- Dados
- Pré-proc.
- Modelo
- Treino

A Figura 2 apresenta a visão estrutural complementar: a organização do software em camadas (Interface, Orquestração, Dados, Modelo, Treino e Otimização, Inferência e Calibração, Avaliação e Métricas, Explicabilidade e Saída) e sua dependência das bibliotecas externas. Cada camada depende apenas de serviços expostos pelas camadas inferiores, o que reduz o acoplamento e facilita a substituição de componentes.

Figura 2. Arquitetura de software em camadas



Fonte: Autoria Própria


4.2 Dados: preparação e divisão por paciente

O pipeline pressupõe o acesso a um arquivo ZIP do IARC Cervical Image Bank, contendo as planilhas “Cases - Images.xlsx” e “Cases Meta data.xlsx” e os arquivos de imagem [2]. A função `prepare_iarc_dataset()` restringe-se às imagens do tipo “After acetic acid”, extrai cada imagem e gera dois manifestos (`manifest.csv`, por imagem; `case_manifest.csv`, por caso). O rótulo binário não é fornecido diretamente: é derivado por mineração de texto do campo “Provisional diagnosis”. `Normalize_text()` limpa o texto, enquanto que `derive_target()` atribui `alto_grau_ou_cancer` caso haja termos como “hsil”, “cin2/3”, “carcinoma” ou “cancer”, e `negativo_ou_baixo_grau` caso contrário. Trata-se de rotulagem fraca (*weak labeling*), cuja limitação (ausência de tratamento de negação) é discutida na Seção 6.

A divisão dos dados é estratificada e realizada no nível do paciente (Figura 3): 70% dos casos para treino e os 30% restantes divididos igualmente entre validação e teste (≈70/15/15). Como um caso pode contribuir com múltiplas imagens, dividir por imagem configuraria vazamento de dados; `load_manifest()`

verifica que cada paciente pertence a uma única divisão, e a avaliação é sempre agregada por caso.

Figura 3. Divisão estratificada no nível do paciente, evitando vazamento de dados entre as divisões.



Fonte: Autoria Própria

4.3 Modelo, aumento de dados e treinamento

A classe CervixImageDataset carrega cada imagem, aplica as transformações e valida o tensor. O pipeline de treino adota um esquema de aumento de dados agressivo, conforme demonstrado na Tabela 2, voltado a mitigar o sobreajuste em um conjunto médico pequeno e levemente desbalanceado; o pipeline de avaliação é determinístico, utilizando variações como redimensionamento, tensor e normalização.

Tabela 2. Operações de aumento de dados aplicadas ao conjunto de treino.

Operação de aumento	Parâmetros
Resize + RandomCrop	sobredimensiona em 15% e recorta para image_size
RandomHorizontalFlip / RandomVerticalFlip	p = 0,50 / p = 0,30
RandomRotation	± 30°
RandomPerspective	distortion_scale = 0,35; p = 0,50
RandomAffine	rot 20°, translação 12%, escala 0,80–1,20, shear 12
ColorJitter	brilho 0,45; contraste 0,40; saturação 0,35; matiz 0,12
Sharpness / Autocontrast / GaussianBlur / Grayscale	p = 0,40 / 0,30 / sempre / 0,05
RandomErasing (×2)	p = 0,35 e p = 0,25 (com escalas distintas)

Fonte: Autoria Própria

A função build_model() instancia, por padrão, uma EfficientNet-B3 pré-treinada na ImageNet [13], escolhida pelo bom equilíbrio entre acurácia e custo proporcionado pelo escalonamento composto. A Tabela 3 lista as quatro arquiteturas efetivamente suportadas.

Tabela 3. Arquiteturas de backbone suportadas por build_model().

Arquitetura	Observações
efficientnet_b3	Padrão; escalonamento composto; equilíbrio acurácia/custo [13]
efficientnet_b4	Maior capacidade e campo receptivo [13]
resnet34	Linha de base com conexões residuais [9]
convnext_tiny	ConvNet moderna; boa calibração [14]

Fonte: Autoria Própria


Independentemente do *backbone*, a camada de classificação é substituída por uma cabeça de duas camadas (Figura 4): Dropout(0,40) → Linear(256) → ReLU → Dropout(0,20) → Linear(1). A transferência de aprendizado ocorre em duas fases (Figura 5): nas primeiras cinco épocas, o backbone é congelado e apenas a cabeça é treinada; em seguida, a rede inteira é ajustada, com taxa de aprendizado do *backbone* igual a 0,1x a da cabeça.

Figura 4. Cabeça de classificação de duas camadas sobre o vetor de características do *backbone*



Fonte: Autoria Própria

Figura 5. Fases da Transferência de aprendizado



Fonte: Autoria Própria

O desbalanceamento entre as classes é tratado pelo `pos_weight` da perda, calculado com a classificação mais baixa e multiplicado por um fator (1,5). Duas perdas estão disponíveis (Tabela 4): a Focal Loss ($\gamma = 2,0$), padrão, que concentra o aprendizado nos exemplos difíceis [15]; e a BCE com suavização de rótulos. O otimizador é o AdamW [10] com taxas diferenciadas, e o agendamento usa CosineAnnealingWarmRestarts ($T_0 = 10$, $T_{mult} = 2$). O

laço de treino aplica MixUp [18] e recorte de norma de gradiente, e calcula métricas de treino e validação por época. A Tabela 5 resume os hiperparâmetros padrão.

Tabela 4. Funções de perda disponíveis (ambas com pos_weight)

Função de perda	Descrição
FocalLoss (padrão)	BCE modulada por $(1 - p_t)^\gamma$, $\gamma = 2,0$; foca exemplos difíceis [15]
LabelSmoothingBCE	BCE com suavização de rótulos de 0,05; melhora a calibração

Fonte: Autoria própria

Tabela 5. Hiperparâmetros padrão de treinamento.


Hiperparâmetro	Valor padrão
architecture / pretrained	efficientnet_b3 / True (ImageNet)
image_size / batch_size	384 × 384 / 16 (8 na CLI)
epochs / freeze_backbone_epochs / patience	30 / 5 / 20
learning_rate (cabeça) / backbone	3×10^{-4} / $0,1 \times$
weight_decay	1×10^{-2}
loss_type / pos_weight_multiplier	focal ($\gamma = 2,0$) / 1,5
mixup_alpha / dropout	0,4 / 0,40 e 0,20
scheduler	CosineAnnealingWarmRestarts ($T_0=10$, $T_{mult}=2$)
temperature_scaling / bootstrap / seed	True / 500 / 42

Fonte: Autoria própria

4.4 Inferência: TTA, calibração e limiar

Na inferência, predict_loader() aplica aumento em tempo de teste com quatro vistas geométricas (original, espelhamentos horizontal, vertical e duplo), cujas probabilidades são calculadas conforme sua média (Figura 6). As predições por imagem são agregadas por paciente, e optimize_threshold() seleciona o limiar que maximiza o F1 score entre aqueles que garantem sensibilidade $\geq 0,80$ - refletindo a prioridade clínica de minimizar falsos negativos. Após o treino, _calibrate_temperature() ajusta um escalar T por L-BFGS [16], suavizando probabilidades super-confiantes sem alterar o ranqueamento; T é armazenado no checkpoint e aplicado em toda inferência.

Figura 6. Inferência: agregação de quatro vistas de TTA, calibração por temperatura e decisão por limiar com restrição de sensibilidade



Fonte: Autoria própria

4.5 Interpretabilidade: Grad-CAM

A explicabilidade visual é fornecida por Grad-CAM [17]: a classe Grad-CAM registra ganchos sobre a última camada convolucional do backbone e combina ativações ponderadas pelos gradientes da classe-alvo para produzir mapas de calor. A função `generate_gradcam_exemplars()` seleciona exemplares de cada quadrante da matriz de confusão (TP/TN/FP/FN), úteis para auditoria de erros, e `generate_gradcam_dataset()` estende a geração a todo o conjunto.

4.6 Organização orientada a objetos e modelagem UML

Quatro classes concentram as responsabilidades de domínio (Tabela 6). A Figura 7 apresenta o diagrama de classes UML, e a Figura 8, o diagrama de dependências.


Tabela 6. Classes do Cervix Visual AI, superclasses e responsabilidades

Classe	Superclasse	Responsabilidade
CervixImageDataset	torch.utils.data.Dataset	Carrega imagens, aplica transformações e valida o tensor.
FocalLoss	torch.nn.Module	Perda Focal com <code>pos_weight</code> ; foca em exemplos difíceis.
LabelSmoothingBCE	torch.nn.Module	BCE com suavização de rótulos e <code>pos_weight</code> .
Grad-CAM	(autônoma)	Registra ganchos e gera o mapa de ativação de classe.

Fonte: Autoria própria

O diagrama de classes (Figura 7) evidencia três generalizações: `FocalLoss` e `LabelSmoothingBCE` especializam `torch.nn.Module`, sobrescrevendo `forward()`; enquanto que `CervixImageDataset` especializa `torch.utils.data.Dataset`, implementando `__len__()` e `__getitem__()`. A classe `GradCAM` não herda de nenhuma superclasse, mas mantém uma associação com um objeto `Module` (o modelo a ser explicado) - composição em vez de herança. Manifestam-se assim os três pilares da orientação a objetos: encapsulamento (o atributo privado `_handles` e os métodos `_register_hooks()/remove_hooks()` de `Grad-CAM`); herança (perdas e `dataset` reutilizando a infraestrutura do PyTorch); e polimorfismo (a variável `criterion` referenciando `FocalLoss` ou `LabelSmoothingBCE`, ambas chamadas via `forward()`).


Figura 7. Diagrama de classes UML: classes de domínio, superclasses do PyTorch e a associação entre Grad-CAM e o modelo



Fonte: Autoria própria

A Figura 8 mostra como a função orquestradora `train_model()` depende de `build_model()` (que instancia o modelo), de uma das funções de perda e de `create_data loaders()` (que encapsula objetos `CervixImageDataset`). Essa separação favorece a manutenibilidade: novas perdas, backbones ou técnicas de interpretabilidade podem ser adicionados sem alterar o laço de treinamento.

Figura 8. Diagrama UML de dependências: train_model() orquestra fábricas, critério de perda, conjunto de dados e explicabilidade



Fonte: Autoria Própria

4.7 Interface de linha de comando

O Cervix Visual AI foi desenvolvido com uma interface de linha de comando (CLI) que organiza as principais funcionalidades do sistema em subcomandos independentes, permitindo executar desde a preparação dos dados até a inferência e a visualização dos resultados. Essa abordagem facilita a utilização do software em diferentes etapas do fluxo de processamento, além de favorecer a reprodutibilidade dos experimentos e a automatização das análises. Na ausência de argumentos fornecidos pelo usuário, o sistema executa automaticamente o subcomando train, iniciando o processo de treinamento do modelo com os parâmetros especificados. A Tabela 7 apresenta os subcomandos disponíveis e suas respectivas funcionalidades.

Tabela 7. Subcomandos da interface de linha de comando.

Comando	Função
prepare	Extraí o ZIP da IARC e gera os manifestos.
demo	Comando prepare seguido de treino com hiperparâmetros fixos.
train	Treino configurável (arquitetura, perda, limiar, temperatura etc.).
evaluate	Reexecuta a avaliação (com TTA e temperatura) sobre um checkpoint.
predict	Inferência em imagem única, com probabilidade calibrada e rótulo.
show	Exibe imagens com Grad-CAM e boundingbox no terminal.

Fonte: Autoria Própria

5. Avaliação

Nesta seção, são descritas as avaliações realizadas pelo modelo Cervix Visual AI, incluindo a análise do desempenho preditivo, das métricas de classificação, da calibração das probabilidades e da interpretabilidade dos resultados, com base nos conjuntos de validação e teste.

5.1 Protocolo e métricas

A avaliação é reportada no nível do caso. A função `binary_metrics()` calcula acurácia, acurácia balanceada, sensibilidade, especificidade, precisão (PPV), valor preditivo negativo, F1 score; quando ambas as classes estão presentes, calcula também AUC-ROC e precisão média. A seleção do melhor modelo a cada época usa um escore composto ($0,5 \times \text{AUC-ROC} + 0,3 \times \text{F1} + 0,2 \times \text{acurácia balanceada}$), equilibrando discriminação e desempenho operacional. A função `bootstrap_confidence_intervals()` realiza 500 reamostragens com reposição por caso, reportando os percentis 2,5 e 97,5 de cada métrica como intervalo de confiança aproximado de 95% - adequado às amostras reduzidas de estudos de centro único utilizadas no estudo.

5.2 Artefatos produzidos

Uma execução completa do subcomando `train` produz o conjunto de artefatos da Tabela 8, incluindo o checkpoint autossuficiente (com limiar e temperatura), os relatórios em JSON, as previsões por caso em CSV, os gráficos e os painéis Grad-CAM.

Tabela 8. Artefatos produzidos por uma execução completa de train.

Artefato	Conteúdo
best_model.pt	Pesos, arquitetura, dropout, image_size, limiar e temperatura.
training_history.json	Métricas de treino/validação e limiar por época.
training_summary.json	Resumo: dispositivo, tempo, peso positivo, melhor época.
evaluation_metrics.json	Métricas por divisão (imagem e caso) com intervalo de confiança por bootstrap.
{split}_case_predictions.csv	Probabilidade e predição por caso, por divisão.
Gráficos (PNG/HTML)	Perda, ROC, F1 score, precisão-revocação, matriz de confusão, painel.
Painéis Grad-CAM	Exemplares positivos, negativos, falsos positivos e falsos negativos e mapas do conjunto completo.

Fonte: Autoria Própria

5.3 Evolução do pipeline

Ao longo da construção do software, diversas abordagens e alterações nos hiperparâmetros foram realizadas. A Tabela 9 sintetiza a evolução entre a versão inicial (utilizando-se a arquitetura ResNet-34) e a versão atual (utilizando-se a arquitetura EfficientNet-B3), evidenciando tanto correções de defeitos quanto a incorporação de novas técnicas - o resultado direto da metodologia iterativa está descrita na Seção 3.3.

Tabela 9. Evolução do pipeline entre as iterações de desenvolvimento.

Aspecto	Versão inicial (ResNet-34)	Versão atual (EfficientNet-B3)
Backbone	Apenas ResNet-34 (EfficientNet não construído)	EfficientNet-B3/B4, ResNet-34, ConvNeXt-Tiny
Cabeça	Dropout → Linear(1)	Dropout → Linear(256) → ReLU → Dropout → Linear(1)
Perda	BCE com suavização	Focal Loss (padrão) + BCE com suavização
Scheduler	ReduceLROnPlateau	CosineAnnealingWarmRestarts
TTA	2 vistas	4 vistas (original, horizontal, vertical, horizontal e vertical)
Calibração	Ausente	Escalonamento de temperatura (L-BFGS)
Limiar	Maximiza o F1 score	Maximiza F1 score com sensibilidade $\geq 0,80$
Early stopping	Inoperante	Corrigido e funcional
Interpretabilidade	Ausente	Grad-CAM (exemplares e conjunto)
Inferência única	Retornava logit bruto	Probabilidade calibrada + rótulo

Fonte: Autoria Própria

5.4 Resultados esperados e contextualização

O modelo Cervix Visual AI, baseado na arquitetura EfficientNet-B3 com aprendizado por transferência, foi treinado durante 30 épocas utilizando função de perda Focal Loss, otimização com AdamW e agendamento da taxa de aprendizado por CosineAnnealingWarmRestarts. O treinamento foi executado em ambiente com uma GPU NVIDIA GeForce GTX 1660 SUPER, empregando validação estratificada por paciente e posterior avaliação em conjunto de teste independente.

Durante o treinamento com a obtenção das melhores métricas, observou-se redução progressiva da função de perda, que passou de aproximadamente 0,485 na primeira época para 0,382 na última época, indicando convergência do processo de otimização.

A curva de ROC-AUC do conjunto de treinamento apresentou crescimento contínuo, atingindo aproximadamente 0,955 ao final das 30 épocas. O desempenho no conjunto de validação também evoluiu ao longo do treinamento, alcan-

çando ROC-AUC de 0,864, sem evidências de oscilações abruptas ou divergência entre as curvas de treinamento e validação.

O F1-score apresentou comportamento semelhante, aumentando gradativamente tanto no treinamento quanto na validação. Ao final do treinamento, foram observados valores próximos de 0,833 para o conjunto de treinamento e 0,769 para validação, indicando melhoria progressiva da capacidade discriminatória do modelo.

Durante o treinamento foi aplicada a calibração das probabilidades por Temperature Scaling, resultando em um parâmetro $T = 0,8602$, utilizado para melhorar a confiabilidade das probabilidades estimadas durante a inferência.

Em relação à seleção do melhor modelo, a escolha do *checkpoint* foi baseada na combinação de métricas de desempenho durante a validação. O melhor modelo foi obtido na época 29, apresentando um ROC-AUC de 0,8889, F1-score de 0,8462, sensibilidade de 1,000 e especificidade de 0,7778, com um *loss* de 0,3420. Além disso, observou-se uma maior sensibilidade (1,0000) já na época 7, fruto dos hiperparâmetros que priorizam esta métrica; uma maior especificidade (0,8333) na época 24; e um menor valor da função de perda (0,3340) na época 27. Esses resultados indicam que o critério de seleção privilegiou um modelo com elevado equilíbrio entre capacidade discriminatória e sensibilidade clínica.

No conjunto de validação, o modelo apresentou desempenho consistente em todas as métricas avaliadas, conforme descrito abaixo.

Foram obtidos:

- ROC-AUC: 0,889
- Average Precision (AP): 0,721
- F1-score: 0,846
- Sensibilidade: 1,000
- Especificidade: 0,778
- Acurácia Balanceada: 0,889
- Acurácia: 0,862

A matriz de confusão demonstrou 14 verdadeiros negativos (VN), 11 verdadeiros positivos (VP), 4 falsos positivos (FP) e 0 falsos negativos (FN). A ausência de falsos negativos resultou em uma sensibilidade de **100%**, indicando que todos os casos positivos presentes no conjunto de validação foram corretamente identificados pelo modelo. Já a curva ROC apresentou AUC de 0,889, evidenciando elevada capacidade de discriminação entre pacientes positivos e negativos.

No conjunto de teste independente, observou-se a redução do desempenho em relação à validação, comportamento esperado devido à utilização de dados completamente não vistos durante o treinamento.

As métricas obtidas foram:

- ROC-AUC: 0,785
- Average Precision (AP): 0,749
- F1-score: 0,545
- Sensibilidade: 0,545
- Especificidade: 0,737
- Acurácia Balanceada: 0,641
- Acurácia: 0,667

A matriz de confusão revelou:

- 14 verdadeiros negativos
- 6 verdadeiros positivos
- 5 falsos positivos
- 5 falsos negativos

Os intervalos de confiança obtidos por bootstrap (95%) foram:

Métrica	Valor	IC95%
ROC-AUC	0,785	0,566–0,932
Average Precision	0,749	0,502–0,927
F1-score	0,545	0,273–0,759
Sensibilidade	0,545	0,250–0,857
Especificidade	0,737	0,525–0,931
Acurácia Balanceada	0,641	0,451–0,810

Embora tenha ocorrido uma redução das métricas no conjunto de teste, a curva ROC permaneceu significativamente acima da linha de classificação aleatória, demonstrando capacidade discriminatória satisfatória.

A comparação entre os dois conjuntos (validação e teste) evidencia a diminuição das métricas de desempenho quando o modelo foi aplicado a dados completamente independentes.

Métrica	Validação	Teste
Acurácia	0,862	0,667
Acurácia Balanceada	0,889	0,641
Precisão	0,733	0,545
F1-score	0,846	0,545

Métrica	Validação	Teste
ROC-AUC	0,889	0,785
Average Precision	0,721	0,749

A maior redução foi observada na sensibilidade, que passou de 1,000 na validação para 0,545 no teste. Em contrapartida, a especificidade apresentou pequena redução (0,778 para 0,737), mantendo desempenho relativamente estável.

Essa diferença entre validação e teste sugere que o modelo apresenta boa capacidade discriminatória, porém ainda possui limitações de generalização, possivelmente relacionadas ao reduzido tamanho da base de dados e à variabilidade inerente às imagens cervicais. Ainda assim, uma ROC-AUC de 0,785 em dados independentes indica que o modelo preserva capacidade relevante para distinguir casos positivos e negativos, demonstrando potencial para o ajuste de hiperparâmetros, métricas e arquiteturas para a sua utilização como ferramenta de apoio ao rastreamento do câncer do colo do útero, desde que validado em bases multicêntricas e de maior dimensão.

6. Discussão: Ética, Limitações e Trabalhos Futuros

No código do software há a declaração de que os resultados são experimentais e não devem ser usados para decisão clínica - afirmação reiterada neste relatório. Há risco de viés algorítmico e de generalização limitada, em razão da heterogeneidade das populações, dos protocolos de aquisição e dos equipamentos utilizados na obtenção das imagens.; qualquer aplicação prática exigiria validação clínica prospectiva [8]. Ferramentas dessa natureza enquadram-se melhor como apoio à decisão do que como diagnóstico autônomo, e os mapas Grad-CAM de o boundingbox contribuem para a sua transparência.

Permanecem limitações que deveriam ser tratadas antes de qualquer relato empírico:

- Rotulagem sem tratamento de negação: a rotulagem por mineração de texto não trata negação, podendo classificar incorretamente textos que descrevam a ausência da condição; outras abordagens podem ser utilizadas para as rotulagens, obtendo-se melhores resultados.
- Caminho padrão específico: o caminho padrão do arquivo .ZIP da IARC é específico do ambiente de desenvolvimento, reduzindo a portabilidade.
- Paralelismo de GPU limitado: o paralelismo de múltiplas GPUs está desativado nesta versão em virtude da incompatibilidade entre keras, Pytorch e Python3.14 e o Compute Unified Device Architecture (CUDA) da NVIDIA. Para os próximos testes, se buscará alternativas para que seja possível a execução dos testes com ambas placas de vídeo em paralelo.

Como trabalhos futuros, poderão ser utilizados: curadoria de rótulos com revisão por especialistas; validação externa em coorte independente; pré-treinamento de domínio e ensembles por validação cruzada; fusão multimodal incorporando HPV, escore de Swede e zona de transformação delimitada como *ground truth* [4]; e a utilização de validação clínica prospectiva.

7. Conclusão

Este relatório técnico descreveu o desenvolvimento completo do Cervix Visual AI, percorrendo a proposta (objetivos, requisitos e metodologia iterativa), o desenvolvimento (arquitetura de software, dados, modelo EfficientNet-B3, treinamento, inferência calibrada, interpretabilidade e projeto orientado a objetos documentado em UML) e a avaliação (protocolo por caso, artefatos, evolução entre versões e contextualização de resultados). O pipeline combina disciplina no tratamento de dados – utilizando-se uma divisão e uma agregação por paciente com quantificação de incerteza - com técnicas modernas de regularização, calibração e explicabilidade, corrigindo defeitos da iteração inicial. Enquadrado como artefato de pesquisa experimental, o software oferece um modelo reproduzível e interpretável, além de um ponto de partida concreto para refinamentos - curadoria de rótulos, validação externa, pré-treinamento de domínio, fusão multimodal e avaliação clínica prospectiva - necessários para que um protótipo evolua, com segurança para as pacientes, em direção a uma ferramenta de apoio ao rastreamento do câncer do colo do útero [1].

Referências

- [1] WORLD HEALTH ORGANIZATION. Global strategy to accelerate the elimination of cervical cancer as a public health problem. Geneva: WHO, 2020.
- [2] INTERNATIONAL AGENCY FOR RESEARCH ON CANCER (IARC). IARC Cervical Cancer Image Bank. Disponível em: <https://screening.iarc.fr/cervicalimagebank.php>. Acesso em: jun. 2026.
- [3] HU, L. et al. An Observational Study of Deep Learning and Automated Evaluation of Cervical Images for Cancer Screening. Journal of the National Cancer Institute, 2019.
- [4] KALBHOR, M. et al. DeepCerviCancer - Deep Learning-Based Cervical Image Classification using Colposcopy and Cytology Images. EAI Endorsed Trans. on Pervasive Health and Technology, 2023.
- [5] SAINI, S. et al. Deep Learning Descriptor Hybridization with Feature Reduction for Accurate Cervical Cancer Colposcopy Image Classification. arXiv:2405.01600, 2024.
- [6] MABEN, L. et al. Automated Cervical Cancer Detection through Visual Inspection with Acetic Acid in Resource-Poor Settings with Lightweight Deep Learning Models Deployed on an Android Device. arXiv:2508.13253, 2025.
- [7] XUE, Z. et al. Image Quality Classification for Automated Visual Evaluation of Cervical Precancer. In: MILLanD 2022, LNCS v. 13559. Cham: Springer, 2022.
- [8] POLI, U. et al. Development and Clinical Validation of a VIA-Artificial Intelligence Tool in Screen-and-Treat Visual Screening for Cervical Cancer in South India: A Pilot Study. JCO Global Oncology, 2024.
- [9] HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: CVPR, 2016.

- [10] LOSHCHILOV, I.; HUTTER, F. Decoupled Weight Decay Regularization. In: ICLR, 2019.
- [11] DENG, J. et al. ImageNet: A Large-Scale Hierarchical Image Database. In: CVPR, 2009.
- [12] WORLD HEALTH ORGANIZATION. New recommendations for screening and treatment to prevent cervical cancer. Geneva: WHO, 2021.
- [13] TAN, M.; LE, Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In: ICML, 2019.
- [14] LIU, Z. et al. A ConvNet for the 2020s. In: CVPR, 2022.
- [15] LIN, T.-Y. et al. Focal Loss for Dense Object Detection. In: ICCV, 2017.
- [16] GUO, C. et al. On Calibration of Modern Neural Networks. In: ICML, 2017.
- [17] SELVARAJU, R. R. et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In: ICCV, 2017.
- [18] ZHANG, H. et al. mixup: Beyond Empirical Risk Minimization. In: ICLR, 2018.